5. 大模型协作记录

5.1 协作任务与责任划分

大模型参与源码检索、方案分析、模块实现、构建脚本组织、日志定位、测试编写和文档整理。设计人员确定目标与约束、审查关键方案，并承担现场接线、启动材料更新及实体交互检查。工程结论以源码、构建报告、数值比较和实板记录为依据。

协作围绕“提出问题—分析约束—形成方案—实现—检查—修正”展开。性能优化保留网络输入、运算范围和数值规则；界面改进保持分类、分割、发布及持久化职责一致，避免局部修复改变其他模块的行为。

5.2 提示词与模型响应

下表提示词为协作记录摘录，模型响应按技术内容归纳。

任务	提示词摘录	模型响应摘要	实施结果
核对原始计算架构	“目前 fpga 上面对于神经网络计算的结构是什么”	检查 HLS 源码、PS 调度和 Vivado 工程，说明原型采用 ARM 调度完整网络、PL 复用一个 FP32 卷积核；区分卷积、非卷积算子与分类头的执行位置。	明确原型为 8 路输出通道并行，逐层调用共享卷积核；将中间数据搬运和 PS 非卷积运算列为优化对象。
确定硬件优化方向	“目前感觉计算速度还是很慢，是否可以将神经网络硬编码进 pl？”	区分固定执行图与全网络电路展开；根据参数存储和算量，提出固定调度、算子融合、DDR 复用及整数化方案。	采用可复用计算阵列，主要算子移入 PL，权重保存在 DDR。

任务	提示词摘录	模型响应摘要	实施结果
讨论频率	“可以将主频拉高吗”	分别分析计算时钟与 DDR 接口时钟，要求重新综合和布局布线，以实际时序确定可用频率。	整数化方案在 125 MHz 实现；增加空间并行后采用 100 MHz 实现。
执行优化方案	“请你按照上面说的去进行修改，主频设置为 150 MHz”	保留原工程，创建独立候选；以 150 MHz 为目标，先进行量化检查，再完成 HLS、整机实现和配套打包。	保留目标尝试记录，最终交付采用通过时序的频率，未将目标频率写为实际达成值。
扩展空间并行	“优化输入打包读取、连续突发传输和窗口复用，做 64 路空间并行，100 MHz 作为可接受目标。”	将输入读取、窗口复用和 64 路空间并行纳入同一候选，以 100 MHz 完成实现检查，保留原运行包供回退。	完成 64 路空间并行方案；初始 BRAM 超限后调整累加缓存端口映射，最终使用 126 个 BRAM Tile。
增加并行度与数据打包	“请你尝试做一下四元素并行拆包/打包＋缓存优化＋128 路空间并行候选”	建立独立候选，先修改四元素拆包与打包、缓存组织，再评估 128 路计算；以资源、时序和关键整数输出决定能否交付。	实现 128 路并行和 64 位通路四元素拆装；通过双副本输入缓存解决端口冲突，核心循环达到 II=1。

任务	提示词摘录	模型响应摘要	实施结果
定位实际等待时间	“手动计算从电脑点击开始到输出结果要 2m10s。帮我看看主要耗时在哪”	对照任务时间戳、逐切片计时和程序字段，区分板端任务时间、推理程序时间与硬件调用时间；将启动前准备、PS 预处理和 B/C 硬件执行分别分析。	日志记录板端任务耗时 129.504 s，与手计约 130 s 接近；B/C 硬件执行为主要耗时。启动前准备包含多项操作，未全部归因于网络上传。
评估后续优化方案	“先不修改代码，检查一下还有哪里可以提速，方案是什么”	只读检查源码及 HLS、时序报告，识别短循环反复启动、输入行重复读取和权重串行拆包；建议保持 128 路、100 MHz，优先改善流水连续性、数据复用及 PS/PL 重叠。	形成连续流水、输入行复用、交错权重供数与预处理重叠方案，经后续实施后纳入最终计算组织。
复核优化收益	“看看这个加速效果？”	对照同一扫描的两次结果，分别核算总时间、程序时间、各分支硬件调用和预处理等待，区分整体时间改善与计算内核变化。	板端任务耗时由 129.504 s 降至 126.281 s，减少 2.49%；程序耗时减少 3.18%，硬件调用累计有所增加。结论限定为单次整体运行改善。

任务	提示词摘录	模型响应摘要	实施结果
当前流水与缓存优化	“先尝试 150 MHz 去弄，如不行就往下回退 125MHz”	调整 AXI 写回、双累加缓冲和特征复用；数值检查后尝试 150 MHz，按最终时序选择频率，并通过正式接口执行完整分类。	150 MHz 建立裕量 −0.557 ns；125 MHz 通过，分类程序 19.893 s、引擎累计 17.742 s，分类字段一致。
分析剩余瓶颈	“你认为目前的速度卡点在哪”	将 B/C 引擎、其他程序工作和网络阶段分别分析，结合输入等待计数及实际时序定位供给和控制链限制。	B/C 累计 17.424 s；BRAM136/140 限制缓存扩展，后续重点转向输入供给、控制流水与数据复用。

协作结果包括可编辑工程、源码、模型文件、启动包、数值检查、资源与时序报告。提示词中的要求通过实际构建与检查落实；无法达到的目标采用有证据支持的方案调整。